

## 第 3 章 3.4~3.5

二又航介

2017 年 5 月 11 日

# 説明変数を組み込んだモデル

## 前回まで

平均種子数  $\lambda$  が全個体で共通であると仮定

## 今回


- 説明変数を組み込んだモデル
  - 個体ごとの平均種子数  $\lambda_i$  を体サイズ  $x_i$  や施肥処理  $f_i$  から推定
- ある個体  $x_i$  において種子数が  $y_i$  である確率  $p(y_i|\lambda_i)$  はポアソン分布に従って
- $$p(y_i|\lambda_i) = \frac{\lambda_{yi} \exp(-\lambda_i)}{y_i!}$$

# 線形予測子とリンク関数

## $x_i$ による $\lambda_i$ の関数

- 個体  $x_i$  の差異によって種子数  $\lambda_i$  を求める関数を定義
- ある個体  $x_i$  の平均種子数  $\lambda_i$  が
  - $\lambda_i = \exp(\beta_1 + \beta_2 x_i)$  として仮定

$\lambda_i = \exp(\beta_1 + \beta_2 x_i)$  のグラフ



# 線形予測子、リンク関数

## 線形予測子

- $\log \lambda_i = \beta_1 + \beta_2 x_i$
- 線形結合 (定数倍したパラメータ同士を和算したもの) で表される
- $\log \lambda_i = \beta_1 + \beta_2 x_i + \beta_3 x_i^2$  でも良い

## リンク関数

- ( $\lambda$  の関数) = (線形予測子) の関係
- 対数リンク関数
- $\lambda_i = \exp(\text{線形予測子}) \geq 0$

# あてはめとあてはまりの良さ

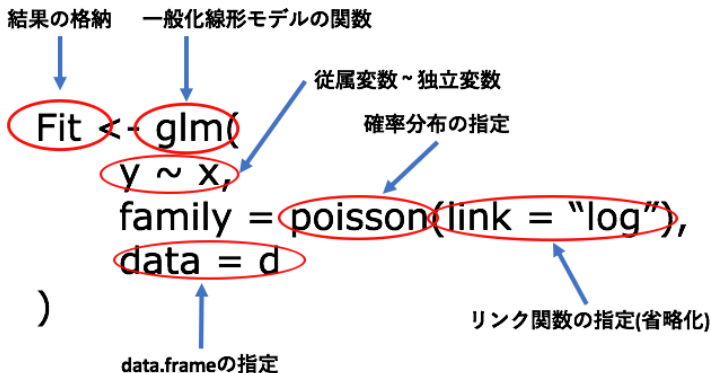
## ポアソン回帰

- 観測データに対するポアソン分布を用いた統計モデルのあてはめ
- 対数尤度  $\log L$  が最大となるパラメーター  $\hat{\beta}_1, \hat{\beta}_2$  の推定値を決定

$$\log L(\beta_1, \beta_2) = \sum_i \log \frac{\lambda_i^{y_i} \exp(-\lambda_i)}{y_i!}$$

- $\lambda_i$  が  $\beta_1$  と  $\beta_2$  の関数
- 線形予測子:  $\log \lambda_i = \beta_1 + \beta_2 x_i$

# glm() 関数の引数の指定方法



# 指定できる確率分布

```
Fit <- glm(  
  y ~ x,  
  family = poisson(link = "log"),  
  data = d  
)
```

| 確率分布 (family)    | 離散 or 連続 | 範囲                     |
|------------------|----------|------------------------|
| binomial         | 離散変数     | $0 \sim +\infty$       |
| gaussian         | 連続変数     | $-\infty \sim +\infty$ |
| Gamma            | 連続変数     | $0 \sim +\infty$       |
| inverse.gaussian | 連続変数     | $0 \sim +\infty$       |
| poisson          | 離散変数     | $0 \sim +\infty$       |
| quasi            | 擬似尤度モデル  | .                      |

- 従属変数の分布を可視化して当てはまりそうなものを選択

# 指定できるリンク関数

```
Fit <- glm(  
  y ~ x,  
  family = poisson(link = "log"),  
  data = d  
)
```

| リンク関数             | 名前      | 式                                    |
|-------------------|---------|--------------------------------------|
| identity          | 恒等リンク   | $\lambda = x$                        |
| log               | 対数リンク   | $\log \lambda = x$                   |
| logit             | ロジットリンク | $\log \frac{\lambda}{\lambda-1} = x$ |
| sqrt              | 平方根リンク  | $\sqrt{\lambda} = x$                 |
| 1/mu <sup>2</sup> | .       | $\frac{1}{\lambda^2} = x$            |
| inverse           | 逆数リンク   | $\frac{1}{\lambda} = x$              |
| power             | べき乗リンク  | $\lambda^n = x$                      |



# 確率分布とリンク関数の組み合わせ

| Family           | リンク関数   |
|------------------|---|
| binomial         | logit, probit, log, cloglog                                       |
| gaussian         | identity, log, inverse  |
| Gamma            | identity, inverse, log  |
| inverse.gaussian | $\frac{1}{\mu^2}$ , identity, inverse, log                        |
| poisson          | identity, log, sqrt   |
| quasi            | logit, probit, cloglog, identity, inverse, log, $\frac{1}{\mu^2}$ |

## 結果の見かた 実行結果

Summary(fit)

Coefficients:

|             | Estimate | Std. Error | z value | Pr(> z ) |     |
|-------------|----------|------------|---------|----------|-----|
| (Intercept) | 1.29172  | 0.36369    | 3.552   | 0.000383 | *** |
| X           | 0.07566  | 0.03560    | 2.125   | 0.033580 | *   |

# 結果の見かた 切片、傾き

Summary(fit)

Coefficients:

|             | Estimate | Std. Error | z value | Pr(> z ) |     |
|-------------|----------|------------|---------|----------|-----|
| (Intercept) | 1.29172  | 0.36369    | 3.552   | 0.000383 | *** |
| X           | 0.07566  | 0.03560    | 2.125   | 0.033580 | *   |

$$\lambda_i = \exp(\underbrace{\beta_1}_{\text{切片}} + \underbrace{\beta_2 x_i}_{\text{傾き}})$$

- 最尤推定値

- $\hat{\beta}_1 = 1.29$  ,  $\hat{\beta}_2 = 0.0757$
- $\log \lambda_i = 1.29 + 0.0757x_i$

# 結果の見かた 標準誤差

Summary(fit)

Coefficients:

|             | Estimate | Std. Error | z value | Pr(> z ) |     |
|-------------|----------|------------|---------|----------|-----|
| (Intercept) | 1.29172  | 0.36369    | 3.552   | 0.000383 | *** |
| X           | 0.07566  | 0.03560    | 2.125   | 0.033580 | *   |

Std. Error: 標準誤差

- 推定値  $\hat{\beta}_1, \hat{\beta}_2$  のばらつきを標準偏差で表したもの
- 推定値の精度についての指標となる

# 結果の見かた z 値

Summary(fit)

Coefficients:

|             | Estimate | Std. Error | z value | Pr(> z ) |     |
|-------------|----------|------------|---------|----------|-----|
| (Intercept) | 1.29172  | 0.36369    | 3.552   | 0.000383 | *** |
| X           | 0.07566  | 0.03560    | 2.125   | 0.033580 | *   |

## Z value: Z 値

- 最尤推定量を Std. Error で割った値 ( $\frac{Estimate}{Std.Error}$ )
- Wald 統計量
  - Wald 信頼区間を構成
  - 推定値が 0 から十分に離れているかの確認
  - 値が大きければ大きいほど離れている
- 0 から離れている  $\simeq$  信頼できる推定値

## 結果の見かた $Pr(>|z|)$

Summary(fit)

Coefficients:

|             | Estimate | Std. Error | z value | $Pr(> z )$ |     |
|-------------|----------|------------|---------|------------|-----|
| (Intercept) | 1.29172  | 0.36369    | 3.552   | 0.000383   | *** |
| X           | 0.07566  | 0.03560    | 2.125   | 0.033580   | *   |

$Pr(>|z|)$ : p 値

- 数値が大きいほど z 値が 0 に近い  $\simeq$  推定値が 0 に近い
- p 値として考えらるが、信頼区間として捉えるほうが良い
- 小さい値であるほど信頼区間が狭い  $\simeq$  推定値が信頼できる

## 結果の見かた 最大対数尤度

```
>logLik(fit)
'log Lik.' -235.3863 (df=2)
```


### 最大対数尤度

- $\log L(\beta_1, \beta_2)$  が最大
- モデルの当てはまりの良さの指標
- df:自由度
  - 最尤推定したパラメーターの個数
  - 今回は  $\beta_1$  と  $\beta_2$  の 2 個

# モデルの可視化

```
> plot(d$x, d$y, pch = c(21, 19)[d$f])  
> xx <- seq(min(d$x), max(d$x), length = 100)  
> lines(xx, exp(1.29 + 0.0757 * xx), lwd = 2)
```

$$\lambda = \exp(1.29 + 0.0757x)$$





# 説明変数が因子型の統計モデル

## 施肥処理を説明変数に利用

- 因子型の説明変数はダミー変数で表される
- 種子数  $y$  が施肥処理の有無  $f$  に関係あると仮定
- $\lambda_i = \exp(\beta_1 + \beta_3 d_i)$  の関係

$$d_i = \begin{cases} 0 & f_i = C \text{ の場合} \\ 1 & f_i = T \text{ の場合} \end{cases}$$

- 個体  $i$  が肥料なし ( $f_i = C$ ) の場合
  - $\lambda_i = \exp(\beta_1)$
- 施肥処理した場合 ( $f_i = T$ )
  - $\lambda_i = \exp(\beta_1 + \beta_3)$

## 結果の見かた 実行結果

```
> fit.f <- glm(y ~ f, data=d, family = poisson)
> fit.f
```

Call: glm(formula = y ~ f, family = poisson, data = d)

Coefficients:

|             |         |
|-------------|---------|
| (Intercept) | fT      |
| 2.05156     | 0.01277 |

$$\lambda_i = \exp(\underbrace{\beta_1}_{\text{切片}} + \underbrace{\beta_3 x_i}_{\text{傾き}})$$

- 最尤推定値

- $\hat{\beta}_1 = 2.05, \hat{\beta}_3 = 0.01277$
- $\log \lambda_i = 2.05 + 0.0128x_i$

## 結果の見かた, 実行結果

- $f_i = C$  の時,
  - $\lambda_i = \exp(2.05 + 0) = \exp(2.05) = 7.77$
- $f_i = T$  の時,
  - $\lambda_i = \exp(2.05 + 0.128) = \exp(2.0628) = 7.87$

「肥料をやると平均種子数が少しだけ増える」と予想

**logLik(fit.f)**  
**'log Lik.' -237.6273 (df=2)**

- $x_i$  だけのモデルの対数尤度-235.4 より当てはまりが悪い