

# GLMのベイズモデル化と 事後分布の推定（導入）

太田研4年 和田

# 統計モデル(線形予測子込み)のベイズ化 + 事後分布からのMCMCサンプリング


## 7章：GLMM

$$\text{logit}(q_i) = \beta_1 + \beta_2 x_i + r_i$$

- ・ 観測され得ないデータを変数に
- ・ 確率分布を入れ子にできる

## 8章前半：MCMC

- ・ 最尤推定の方法の一種
- ・ 試行回数を重ねると最良のパラを中心に分布



## 8章後半：ベイズ統計モデル

- ・ 世の中の現象は確率分布で表せる
- ・ 事後分布  $\propto$  尤度  $\times$  事前分布(定数)

一つに統合！！

- ・ 線形予測子  $\times$  事後分布公式
- ・ 事後分布  $\times$  MCMC


## 9.1 今回扱う例題（注：too simple）

- 植物が20個体いる（個体 $i$ ,  $i=1\sim 20$ ）
- 各個体の種子数 $y_i$ （データあり）
- $\uparrow$  体の大きさ $x_i$ に依存（ $x_i$ が種子数平均を決定）

《仮定》

- 個体差は存在しない
  - ランダム効果はなし
- 種子数 $y_i$ のばらつきは $\lambda_i$ のポアソン分布
- $\lambda_i = \exp(\beta_1 + \beta_2 x_i)$

→ 普通のポアソン回帰GLMで算出可能



## 9.2. GLMのベイズモデル化

種子数 $y_i$ のばらつきは $\lambda_i$ のポアソン分布  
$$\lambda_i = \exp(\beta_1 + \beta_2 x_i)$$

- 尤度関数  $L(\beta_1, \beta_2) = \prod p(y_i | \lambda_i) = \prod p(y_i | \beta_1, \beta_2, x_i)$ 
  - ポアソン分布なので；離散確率分布！
  - $p(\beta_1, \beta_2 | Y) = L(\beta_1, \beta_2)$
- 事後分布  $\propto$  尤度  $\times$  事前分布 より
- $p(\beta_1, \beta_2 | Y) \propto p(Y | \beta_1, \beta_2) p(\beta_1) p(\beta_2)$

それぞれ $\beta_1, \beta_2$ の事前分布

これを適切に指定すると…  
GLMのベイズモデル化！

## 9.3 無情報事前分布 —事前分布をどう設定するのか—

- 事前分布は「観測データが得られてない時の、パラの確率分布」

? ! ? ! そんなのわからないでしょ ! ! !

→  $[-\infty, \infty]$ の範囲で好きな値をとっていい … 「無情報事前分布」

- 無限区間の一様分布？ → (確率分布なのに) 積分が1にならない

妥協案 1

$-10^9 < \beta < 10^9$ の範囲の  
一様分布

妥協案 2

異常に平べったい正規分布  
(e.g. 平均0,  $\sigma=100$ )

疑問

なぜ好きな値  
なのに一様？  
なぜ正規分  
布？